

ЛАБОРАТОРНАЯ РАБОТА 1

МЕТОДЫ ПАКЕТНОЙ ОБРАБОТКИ ДАННЫХ

Задачи:

- Освоить архитектуру MapReduce и реализовать подсчёт слов на HDFS;
- Развернуть и использовать кластер Apache Spark для пакетной обработки данных;
- Реализовать алгоритмы WordCount и PageRank с использованием Spark RDD и DataFrame API;
- Изучить приёмы оптимизации Spark-приложений: настройка числа партиций, использование кэширования, контроль локальности данных;
- Сравнить подходы Hadoop и Spark с точки зрения производительности, удобства разработки и повторного использования данных.

Шаги:

1. Написать и запустить классический MapReduce «WordCount» на HDFS:
 - а. input-файл (100 MB текста).
 - б. Скомпилировать Java-приложение и запустить через `hadoop jar`.
 - в. Проанализировать вывод.
2. Развернуть кластер Spark (master + 2 workers) в Docker;
3. Написать Spark-приложение на Python/Scala:
 - а. WordCount (использовать RDD и DataFrame);
 - б. PageRank на небольшом графе из 1000 вершин.
4. Исследовать влияние партиционирования: Изменять число партиций и измерять время выполнения.
5. Использовать `repartition` / `coalesce`.
6. Показать использование `persist/cache` и сравнить время выполнения с кешем и без.
7. Использовать Spark Web UI:
 - а. Изучить DAG, стадии, и задачи;
 - б. отметить, где происходят shuffle-операции и где задействовано кэширование.